Semantische Datenintegration

Integration von Dokumentformaten

Jakob Voß

2017-04-01

Dokumente

Was ist ein Dokument?

- Kernbegriff der Dokumentationswissenschaft
- Nicht einfach zu beantworten (Buckland 1997)
- Definition von Briet (1951)

  A document is evidence in support of a fact [. . .] any physical or symbolic sign, preserved or recorded, intended to represent, to reconstruct, or to demonstrate a physical or conceptual phenomenon

Beispiele für Dokumente?

- ...
- ...
- ...
- ...

Beispiele für Dokumente

- Archäologische Objekte
- Spuren
- Publikationen
- Kunstwerke (sic)

Daten als digitale Dokumente

- Auffassungen von Daten
  - Daten als Fakten ($\Rightarrow$ Fachgebiete)
  - Daten als Beobachtungen ($\Rightarrow$ Statistik)
  - Daten als Dokumente ($\Rightarrow$ Informationsmanagement)
- Semiotischer Ansatz: Daten/Dokumente als Zeichen für etwas
- Dokumente haben
  - Ursprung, Zwecke, Adressaten...
  - Form (*hier Thema*)

Dokumentformate

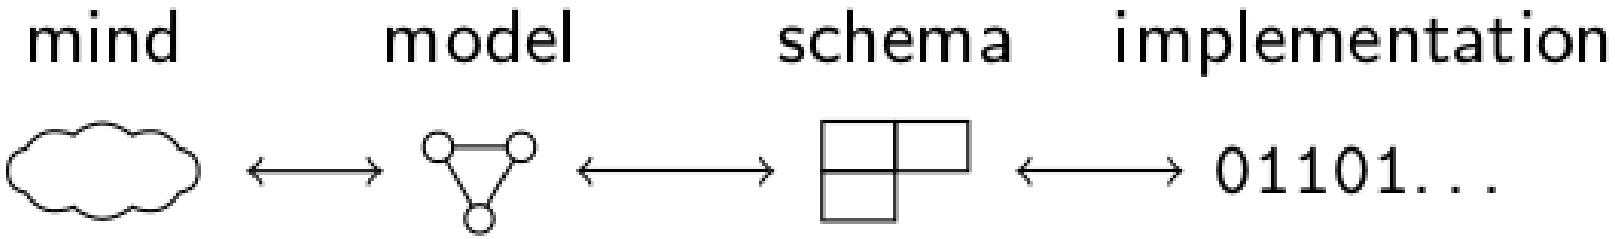

Wo finden wir Daten-/Dokumentenformate?

Arten von Datensprachen

- Modellierungs-Sprachen (UML, ERM...)
- **Schema-Sprachen** (RDF Schema, XML Schema, RegExp...)
  - Abfragesprachen (SQL, XPath...)
- **Datenstrukturierungssprachen** (CSV, XML, JSON...)
  - Auszeichnungssprachen (HTML, TEI, Markdown...)
- Kodierungen (Unicode, ASCII, Binärcode...)

Beschreibung von Datenformaten

- Spezifikationen/Standards
- Schemata
  - z.B. ein XML-Schema für ein XML-Format
- Implementierungen (!)
- Datenstrukturierungssprache als Grundlage
  - z.B. XML für ein XML-Format

Dateiformate

- Beliebige Datenformate für Daten in Dateien
- Oft Containerformate (MPEG, PDF...)
- Oft weitere Dateien/Datenbanken als Grundlage (z.B. ODT)
- *Ist "Datei" nicht zunehmend eine Methapher?*

Exkurs: MIME-Type

- 1996: Multipurpose Internet Mail Extensions (MIME, 1996)
- content type / media type
- Verwendet u.A. in HTTP-Nachrichten
- Identifier für Dateiformate

$\Longrightarrow$ *IANA list of official media types*

Übung: Anatomie einer OpenDocument-Datei

- ...

Medienformate

aka *Content-Formate*

- Formate und Kodierungen für “Inhalte”
- Audio-, Video-, Bild-Formate
  - Eigenes Thema, mehr Mathematik
- Prinzipiell alle Arten digitaler Dokumente

Dokumentformate im engeren Sinne

- Seitenbeschreibungsprachen
  - PDF, PostScript, DVI...
- Dokumentformate für (Text-)Dokumente
  - OpenDocument Format
  - Plain Text
  - HTML
  - LaTeX
  - TEI
  - DocBook
  - EPUB
  - ...
- Basieren meist auf Auszeichnungssprachen

Auszeichnungssprachen

Was sind Auszeichnungssprachen?

- Modellierungs-Sprachen (UML, ERM...)
- Schema-Sprachen (RDF Schema, XML Schema, RegExp...)
  - Abfragesprachen (SQL, XPath...)
- Datenstrukturierungssprachen (CSV, XML, JSON...)
  - **Auszeichnungssprachen** (HTML, TEI, Markdown...)
- Kodierungen (Unicode, ASCII, Binärcode...)

Beispiel: HTML

- Basiert (theoretisch) auf SGML/XML
- Spezifikation durch W3C
- Deskriptive Elemente (`<title>`, `<h1>`, `<em>`, `<code>`...)
- Präsentative Elemente (`<i>`, `<tt>`...)
- Legt zusammen mit CSS allgemeines Erscheinungsbild einer Webseite (oder EPUB, UI...) fest ("HTML-Design")

Beispiel: TEI

- Text-Encoding Initiative (TEI) seit 1987 (!)
- Basierte auf SGML, inzwischen XML
- Verbreitet für Texteditionen in den Digital Humanities
- Umfangreiches Regelwerk der TEI
  - Mehr als 500 Elemente
  - Mehrere Module und Schemata
- Beschreibt welche Inhalte in einem Dokument vorkommen (deskriptiv)

Beispiel für TEI

Beispiel: <surface> und <zone>

Welche Oberfläche, welche Zonen/Bereiche könnte man hier unterscheiden?

- Surface: die gesamte Seite
- Zone 1: Nummer oben rechts
- Zone 2: Textblock oben
- Zone 3: Textblock unten
- Zone 4: Titel unten rechts
- evtl. Zone 5: Verfärbung (Polygon)

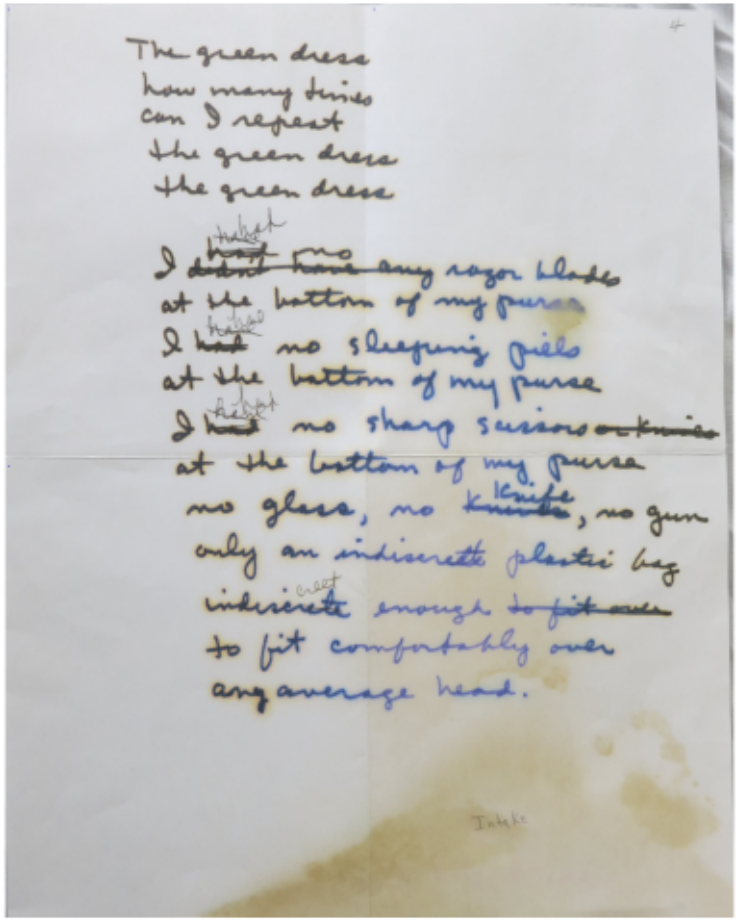

Beispiel: Markdown

- Einfache Bearbeitung von Texten
- Beschränkung auf typische Elemente
  - Überschriften
  - Absätze, Listen, Tabellen, Bilder,
  - Fett, Kursiv
  - ...

Übung: Markdown-Bearbeitung mit HackMD

`https://hackmd.io/`

Anwendungsschwerpunkte von Auszeichnungssprachen

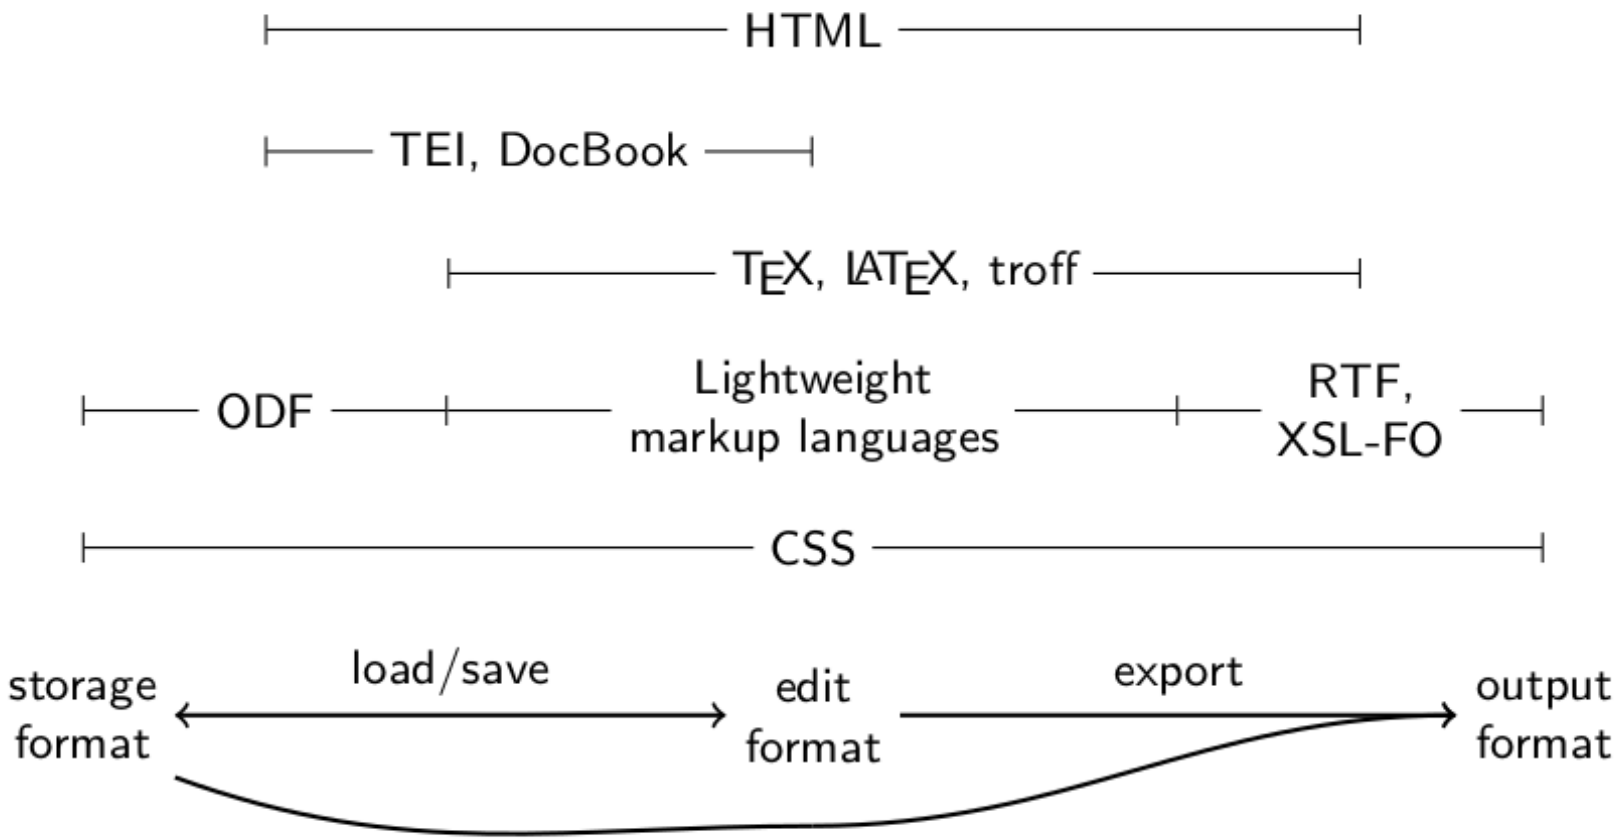

Vergleich von Auszeichnungssprachen

language	bold face	italic face	monospace	sub-/superscript
DocBook	`<emphasis role='strong'>`	`<emphasis>`, `<firstterm>`	`<code>`, `<varname>`	`<subscript>`, `<superscript>`
HTML	`<b>`	`<t>`	`<tt>`, `<code>`	`<sub>`, `<sup>`
TEI	`<hi rend="bold">`	`rend="italics"`	`rend="typewriter"`	`rend="subscript"`, `rend="superscript"`
TEX	`\textbf {text}`	`\textit {text}`, `\emph {text}`	`\texttt {text}`, `\verb #text#`	`^{text}`, `_{text}`
RTF	`{\b text}`	`{\i text}`	`{\fmodern text}`	`{\sub text}`, `{\sup text}`
MediaWiki	`'''text'''`	`''text''`	`<tt>`, `<code>`	`<sub>`, `<sup>`
Markdown	`**text**`, `__text__`	`*text*`, `_text_`	``` ``text`` ```	`<sub>`, `<sup>`
Textile	`*text*`	`_text_`	`@text@`	`~text~`, `^text^`
reStructuredText	`**text**`	`*text*`	``` ``text`` ```	`:sub:`text``, `:sup:`text``
POD	`B<text>`	`I<text>`	`C<text>`	–
GNU troff (man)	`.fam B text .fam`, `\fBtext \fP`	`.fam I text .fam`, `\fItext \fP`	`.fam C text .fam`, `\fCtext \fP`	`^text^`, `~text~`

Konvertierung zwischen Dokumentformaten

Eingangsformat $\longrightarrow$ **Dokumentmodell** $\longrightarrow$ Ausgangsformat

- Datenmodell von Dokumentstrukturen
- Tool: Pandoc
  - `https://pandoc.org/`
  - `https://cloudconvert.com/`
    `https://foliovision.com/seo-tools/pandoc-online`
    `...`

Pandoc-Filter mit Pandoc::Elements (Perl)

```perl
use Pandoc::Filter qw(pandoc_filter);
use Pandoc::Elements qw(BulletList Para Strong Str);

pandoc_filter DefinitionList => sub {
    BulletList [ map { to_bullet($_) } @{ $_->items } ]
};

sub to_bullet {
    my $item = shift;
    [ Para [ Strong $item->term ], map { @$_} @{$item->definitions} ]
}
```

Pandoc-Filter mit panflute (Python)

```python
from panflute import toJSONFilter, DefinitionList, BulletList, ListItem

def deflists(elem, doc):
    if type(elem) == DefinitionList:
        bullets = [tobullet(item) for item in elem.content]
        return BulletList(*bullets)

def tobullet(item):
    ans = [Para(Strong(*item.term))]
    for definition in item.definitions:
        for block in definition.content:
            ans.append(block)
    return ListItem(*ans)

if __name__ == "__main__":
    toJSONFilter(deflists)
```

Zusammenfassung und Ausblick

Hypertext

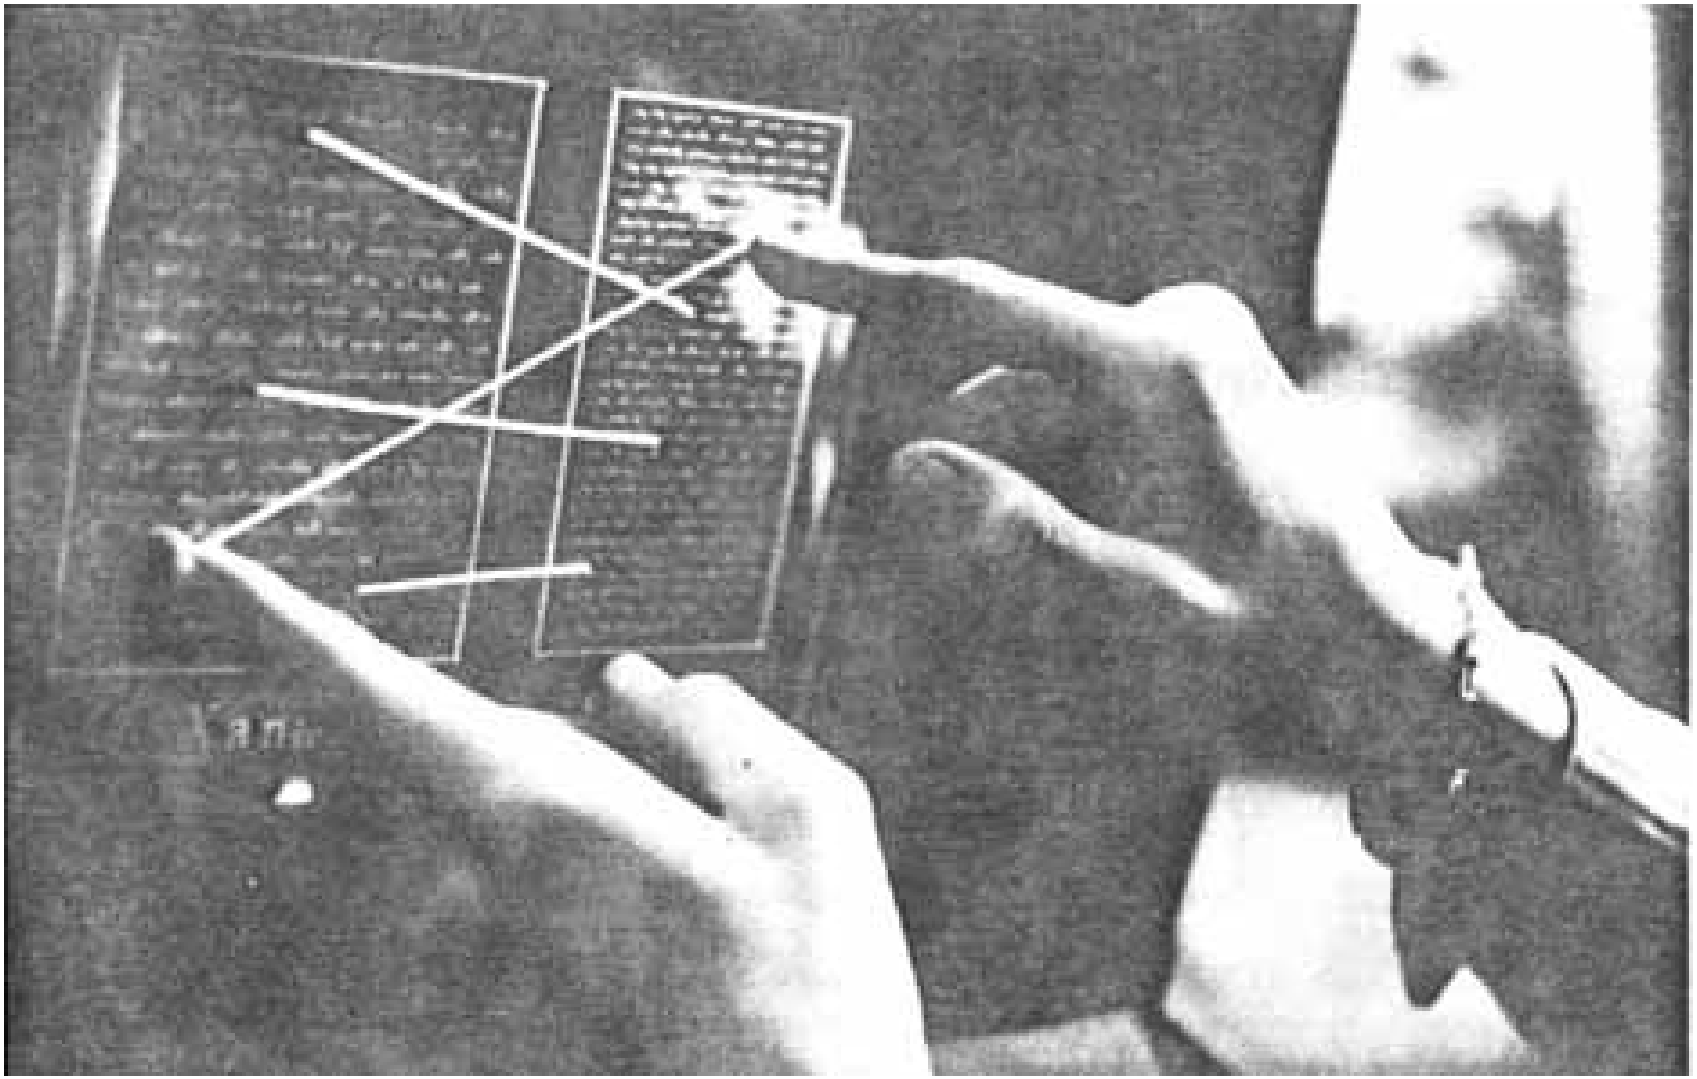

Ted Nelson 1972

Beyond the PDF

- Versionierung
- Annotationen
- Dynamische Dokumente
- Eingebettete Daten
- ...

Beispiele:

- Jupyter/iPython Notebook
- Hypothes.is

Zusammenfassung

- Digitale Dokumente sind Datenobjekte, die als Dokument wahrgenommen werden
- Datenformat
  - Dateiformat
  - Medienformat
    - **Dokumentformat**
- Auszeichnungssprachen
  - gibt es viele
  - basieren auf einem Dokumentmodell
  - haben kleinsten gemeinsamen Nenner

Literatur- und Quellenangaben

Quellcode dieser Folien: `https://github.com/hshdb/MWM-317-02`
Briet, Suzanne. 1951. *Qu'est-ce que la documentation?* Paris: Éditions documentaires, industrielles et techniques.
Buckland, Michael. 1997. „What is a ‚document'¿' *Journal of the American Society of Information Science (JASIST)* 48 (9): 804–9.
Nelson, Theodor Holm. 1999. „Xanalogical Structure, Needed Now More Than Ever: Parallel Documents, Deep Links to Content, Deep Versioning, and Deep Re-Use". *ACM Computing Surveys* 31 (4es). doi:10.1145/345966.346033.